



LISTA DE EXERCÍCIOS - SISTEMAS INTELIGENTES APLICADOS

Lista de Exercícios 2

Naive Bayes

DOCENTE: Thiago França Naves

DATA: 30/09/2026

ALUNO: Mayara Rodrigues Pereira e Leonardo José Reis Pinto

Os testes da questão 1 e da questão 4 foram feitos no Weka 3.8.6, com validação cruzada de 10 dobras, que é o padrão do Explorer. As contas das questões 2 a 5 estão no script `solucao.py` (Apêndice A), que implementa o Naive Bayes por contagem, com frações exatas. A base da questão 4 foi digitada no arquivo `computadores.arff`.

Questão 1

Descreva como funciona o algoritmo Naive Bayes. Em seguida, utiliza a ferramenta Weka e faça testes com o algoritmo utilizando as bases Weather e Diabetes, descreva as diferenças do algoritmos nas duas bases em relação aos valores de acurácia, precisão e matriz de confusão.

Resposta. O Naive Bayes é um classificador probabilístico. Para um exemplo com atributos $a_1, \dots, a_n$, ele calcula para cada classe c o valor

$$P(c) \prod_{i=1}^n P(a_i | c)$$

e escolhe a classe com o maior resultado. A fórmula vem do teorema de Bayes, $P(c | a_1, \dots, a_n) \propto P(c) P(a_1, \dots, a_n | c)$, mais a suposição “ingênua” de que os atributos são independentes entre si quando a classe é conhecida. Essa suposição troca uma tabela conjunta enorme por uma tabela pequena por atributo. O denominador $P(a_1, \dots, a_n)$ é igual para todas as classes e pode ser ignorado.

O treino é só contagem: a fração de exemplos de cada classe dá $P(c)$ e a fração de cada valor de atributo dentro de cada classe dá $P(a_i | c)$. Para atributos numéricos, como os da Diabetes, o Weka ajusta uma distribuição normal por classe, com a média e o desvio de cada atributo, e usa a densidade no lugar da frequência. Para evitar que um valor nunca visto zere o produto inteiro, o Weka soma 1 em todas as contagens (correção de Laplace).

Usamos a `weather.nominal.arff` (14 exemplos, 4 atributos nominais) e a `diabetes.arff` (768 pacientes, 8 atributos numéricos), que vêm com o Weka.




Figura 1. Naive Bayes na Weather, validação cruzada de 10 dobras.




Figura 2. Naive Bayes na Diabetes, validação cruzada de 10 dobras.

Tabela 1. Resumo dos dois testes. ZeroR é a acurácia de chutar sempre a classe mais comum.

Base	Acurácia	ZeroR	Kappa	Precisão por classe
Weather	57,14%	64,29%	-0,024	yes 0,636; no 0,333
Diabetes	76,30%	65,10%	0,466	negativo 0,802; positivo 0,678

Tabela 2. Matrizes de confusão (linhas: classe real; colunas: classe prevista).

Weather	yes	no	Diabetes	negativo	positivo
yes	7	2	negativo	422	78
no	4	1	positivo	104	164

Na Weather o resultado foi ruim: 57,14% de acerto, abaixo dos 64,29% que se teria respondendo sempre “yes”, e kappa negativo, ou seja, pior que o acaso. Das 5 instâncias “no”, só uma foi reconhecida, e por isso a precisão dessa classe ficou em 0,333. A base tem apenas 14 exemplos. Em cada dobra o modelo é treinado com 12 ou 13 e cada estimativa de $P(a_i | c)$ sai de poucas contagens, então um único exemplo muda bastante as probabilidades. Além disso, a classe “no” depende de combinações de atributos (sol com umidade alta, chuva com vento), e o Naive Bayes olha cada atributo separado.

Na Diabetes o comportamento foi o esperado para o algoritmo: 76,30% de acerto, 11 pontos acima do ZeroR, e kappa de 0,466. Com 768 exemplos as médias e desvios de cada classe ficam bem estimados. A matriz mostra que o erro está concentrado nos diabéticos: 104 dos 268 positivos foram classificados como negativos, enquanto só 78 dos 500 negativos foram para o outro lado. Por isso a precisão e o recall da classe positiva (0,678 e 0,612) são menores que os da negativa. A classe negativa é quase o dobro da positiva, o que puxa $P(c)$ a favor dela, e os valores de glicose e IMC dos dois grupos se sobrepõem bastante.

Questão 2

Considere o seguinte conjunto de treino. Nestas condições, determine justificando, a classificação obtida pelo algoritmo Naive Bayes para os seguintes exemplos: a. $\langle \text{Sunny, Cool, High, Strong} \rangle$; b. $\langle \text{Overcast, Hot, Normal, Strong} \rangle$; c. $\langle \text{Rainy, Cool, High, Weak} \rangle$.

Resposta. A tabela da lista tem 13 exemplos, 9 “Yes” e 4 “No”. Então $P(\text{Yes}) = 9/13$ e $P(\text{No}) = 4/13$. As contagens por classe ficaram assim:

Tabela 3. Contagens de cada valor por classe (Yes / No).

Outlook	Temp	Humidity	Wind
Sunny 2 / 3	Hot 2 / 2	High 3 / 3	Weak 6 / 2
Overcast 4 / 0	Mild 4 / 1	Normal 6 / 1	Strong 3 / 2
Rainy 3 / 1	Cool 3 / 1		

Sem correção de Laplace, como é feito à mão em aula:

a) $\langle \text{Sunny, Cool, High, Strong} \rangle$

$$\begin{aligned}\text{Yes} &: \frac{9}{13} \cdot \frac{2}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} = 0,00570 \\ \text{No} &: \frac{4}{13} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{3}{4} \cdot \frac{2}{4} = 0,02163\end{aligned}$$

Classificado como **No** (79% depois de normalizar). Sol, umidade alta e vento forte aparecem proporcionalmente mais nos dias “No”.

b) $\langle \text{Overcast, Hot, Normal, Strong} \rangle$

$$\begin{aligned}\text{Yes} &: \frac{9}{13} \cdot \frac{4}{9} \cdot \frac{2}{9} \cdot \frac{6}{9} \cdot \frac{3}{9} = 0,01519 \\ \text{No} &: \frac{4}{13} \cdot \frac{0}{4} \cdot \dots = 0\end{aligned}$$

Classificado como **Yes**. Nenhum dia nublado da base é “No”, então $P(\text{Overcast} \mid \text{No}) = 0$ e a classe “No” fica zerada, não importa o resto. Com Laplace o resultado continuaria “Yes”, mas sem o zero absoluto.

c) (Rainy, Cool, High, Weak)

$$\text{Yes} : \frac{9}{13} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{3}{9} \cdot \frac{6}{9} = 0,01709$$

$$\text{No} : \frac{4}{13} \cdot \frac{1}{4} \cdot \frac{1}{4} \cdot \frac{3}{4} \cdot \frac{2}{4} = 0,00721$$

Classificado como **Yes** (70%).

Questão 3

Para este problema considere o espaço de instâncias representado pelo espaço booleano de 6 dimensões e admita que lhe é fornecido um conjunto de treino que inclui todas as instâncias deste espaço, rotulado de acordo com a expressão booleana $f = x_1 \vee \neg x_1 x_2 x_3$. a. Determine a classificação obtida para a instância 100010, utilizando o algoritmo Naive Bayes. c. Repita a alínea anterior para a instância 011011. d. Comente os resultados obtidos e indique, justificando detalhadamente, se, neste problema estão satisfeitas as condições para que este classificador seja ótimo.

Resposta. O conjunto de treino tem as $2^6 = 64$ instâncias. São positivas as 32 com $x_1 = 1$ e as 8 com $x_1 = 0, x_2 = x_3 = 1$ (com x_4, x_5 e x_6 livres), 40 no total. As outras 24 são negativas. Assim $P(+)=40/64$ e $P(-)=24/64$. Contando os uns em cada classe:

Tabela 4. Probabilidade de cada atributo valer 1 em cada classe.

	x_1	x_2	x_3	x_4	x_5	x_6
$P(x_i = 1 \mid +)$	4/5	3/5	3/5	1/2	1/2	1/2
$P(x_i = 1 \mid -)$	0	1/3	1/3	1/2	1/2	1/2

a) Para 100010, o termo $P(x_1 = 1 \mid -) = 0$ zera a classe negativa. A positiva vale $\frac{40}{64} \cdot \frac{4}{5} \cdot \frac{2}{5} \cdot \frac{2}{5} \cdot \frac{1}{2} \cdot \frac{1}{2} = 0,0100$, e o exemplo é classificado como **positivo**, o que está certo, já que $x_1 = 1$.

c) Para 011011:

$$+ : \frac{40}{64} \cdot \frac{1}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = 0,00563$$

$$- : \frac{24}{64} \cdot 1 \cdot \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = 0,00521$$

Classificado como **positivo**, também certo, porque $\neg x_1 x_2 x_3$ é verdadeiro. Mas a margem foi pequena: 51,9% contra 48,1%, quando a resposta verdadeira é positiva com certeza.

d) O Naive Bayes é o classificador bayesiano ótimo quando os atributos são condicionalmente independentes dada a classe. Aqui isso não acontece. Dentro da classe positiva, se $x_1 = 0$ então obrigatoriamente $x_2 = x_3 = 1$. Por exemplo, $P(x_1 = 0, x_2 = 1 \mid +) = 8/40 = 0,2$, enquanto o produto das marginais dá $P(x_1 = 0 \mid +) P(x_2 = 1 \mid +) = 0,2 \cdot 0,6 = 0,12$. Na classe negativa acontece o mesmo com x_2 e x_3 , que não podem valer 1 ao mesmo tempo. Então as probabilidades que o Naive Bayes calcula estão erradas, e a instância 011011 mostra isso: ele dá 52% para uma classe que é certa.

Mesmo assim, ele classifica corretamente as 64 instâncias, o que conferimos no script. A classificação só precisa que a classe certa tenha o maior valor, e não que as probabilidades estejam certas. Então a condição para o classificador ser ótimo no sentido de probabilidade (independência condicional) não está satisfeita, mas nesse problema ele acerta todas as instâncias. Os atributos x_4, x_5 e x_6 não atrapalham porque têm a mesma distribuição nas duas classes e se cancelam na comparação.

Questão 4

Considere a seguinte base de treino. Simule o método de treino e teste validação cruzada e utilize o algoritmo naive bayes. Em seguida teste essa mesma base no software Weka e informe a acurácia do naive bayes no mesmo.

Resposta. Dividimos os 10 computadores em 5 dobras de 2, na ordem da tabela (1 e 2, 3 e 4, e assim por diante). Em cada rodada, o modelo é treinado com as 8 máquinas das outras dobras e testado nas 2 que ficaram de fora. Usamos correção de Laplace, porque com só 8 exemplos de treino muitas combinações aparecem zero vezes. Sem ela, 3 dos 10 testes zeram as duas classes e a decisão vira empate.

Como exemplo, na dobra 4 o computador 7 (Produção, mais de um ano, uso alto, nunca deu defeito, risco Alto) é testado com um modelo treinado nas máquinas 1 a 6, 9 e 10, que têm 5 de risco Baixo e 3 de risco Alto:

$$\text{Baixo} : \frac{5+1}{8+2} \cdot \frac{4+1}{5+2} \cdot \frac{1+1}{5+3} \cdot \frac{0+1}{5+2} \cdot \frac{3+1}{5+2} = 0,00875$$

$$\text{Alto} : \frac{3+1}{8+2} \cdot \frac{0+1}{3+2} \cdot \frac{1+1}{3+3} \cdot \frac{3+1}{3+2} \cdot \frac{0+1}{3+2} = 0,00427$$

Ele sai como Baixo e é um erro. Nenhum computador de risco Alto do treino é da Produção nem estava sem defeito, e isso pesa mais que o uso alto.

Tabela 5. Resultado de cada dobra.

Dobra	Computador	Real	Previsto
1	1 / 2	Baixo / Alto	Baixo / Alto
2	3 / 4	Baixo / Alto	Baixo / Alto
3	5 / 6	Baixo / Baixo	Baixo / Baixo
4	7 / 8	Alto / Baixo	Baixo / Alto
5	9 / 10	Baixo / Alto	Baixo / Alto

A acurácia simulada foi de 8 em 10, 80%. Os dois erros são os computadores 7 e 8, que são os casos que fogem do padrão: o 7 é de risco Alto mesmo estando na Produção e sem defeito, e o 8 é de risco Baixo mesmo sendo do Escritório com uso alto.

No Weka, com 10 dobras, a acurácia também foi de **80%**, com a matriz [5 1; 1 3]. Com só 10 exemplos, a validação de 10 dobras deixa um computador de fora por vez. Refizemos isso no script (deixando um de fora, com Laplace) e os erros foram os mesmos, computadores 7 e 8, o que confirma que a simulação e o Weka fazem a mesma conta.




Figura 3. Naive Bayes na base dos computadores no Weka.

Questão 5

Aplique o classificador Naive Bayes a base de teste correspondentes aos seguintes assuntos: uma pessoa que está tossindo e com febre, uma pessoa cujo nariz está escorrendo e que sofre de febre, e uma pessoa com nariz escorrendo e pele avermelhada. ($d_7 = (\neg N, C, \neg R, F)$, $d_8 = (N, \neg C, \neg R, F)$ e $d_9 = (N, \neg C, R, \neg F)$).

Resposta. A base tem 3 doentes (d_1 a d_3) e 3 saudáveis (d_4 a d_6), então $P(\text{ill}) = P(\text{healthy}) = 1/2$. Na ordem N, C, R, F:

$$d_7 : \text{ill} : \frac{1}{2} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} = 0,0123$$

$$d_8 : \text{ill} : \frac{1}{2} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} = 0,0123$$

$$d_9 : \text{ill} : \frac{1}{2} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} = 0,0494$$

$$\text{healthy} : \frac{1}{2} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{0}{3} = 0$$

$$\text{healthy} : \frac{1}{2} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{0}{3} = 0$$

$$\text{healthy} : \frac{1}{2} \cdot \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} \cdot \frac{3}{3} = 0,0370$$

Os três são classificados como **doentes (ill)**. Em d_7 e d_8 quem decide é a febre: nenhum saudável da base tem febre, então $P(F | \text{healthy}) = 0$ zera essa classe. Isso é efeito de ter só 6 exemplos, e não uma regra médica. Em d_9 não há febre e a decisão foi apertada, 57% contra 43%.

Com correção de Laplace as três respostas continuam "ill" (d_7 e d_8 com 57% e d_9 com 53%), mas nenhuma classe fica zerada, o que é mais confiável para uma base tão pequena.

Apêndice A. Código

python solucao.py

```
# Lista 2 - Naive Bayes
# Sistemas Inteligentes Aplicados - UTFPR
# Uso: python solucao.py

from fractions import Fraction as F
from itertools import product

def naive_bayes(base, exemplo, laplace=False, valores=None):
    # base: lista de (atributos, classe); devolve o score de cada classe
    classes = sorted(set(c for _, c in base))
    scores = {}
    for c in classes:
        linhas = [x for x, y in base if y == c]
        if laplace:
            score = F(len(linhas) + 1, len(base) + len(classes))
        else:
            score = F(len(linhas), len(base))
        for i, v in enumerate(exemplo):
            iguais = sum(1 for x in linhas if x[i] == v)
            if laplace:
                score *= F(iguais + 1, len(linhas) + len(valores[i]))
            else:
                score *= F(iguais, len(linhas))
        scores[c] = score
    return scores

def mostrar(scores):
    total = sum(scores.values())
    melhor = max(scores, key=scores.get)
    partes = []
    for c, s in scores.items():
        pct = float(s / total) * 100 if total else 0
        partes.append(f"{c}={float(s):.5f} ({pct:.1f}%)" )
    return " ".join(partes) + f" -> {melhor}"

# questao 2
print("[2] base de treino do jogo")
tabela = """Sunny Hot High Weak No
Sunny Hot High Strong No
Overcast Hot High Weak Yes
Rainy Mild High Weak Yes
Rainy Cool Normal Weak Yes
Rainy Cool Normal Strong No
Overcast Cool Normal Strong Yes
Sunny Mild High Weak No
Sunny Cool Normal Weak Yes
Rainy Mild Normal Weak Yes
Sunny Mild Normal Strong Yes
Overcast Mild High Strong Yes
Overcast Hot Normal Weak Yes"""
jogo = []
for linha in tabela.split("\n"):
    p = linha.split()
    jogo.append((p[:4], p[4]))
print(f" {len(jogo)} exemplos, Yes={sum(c == 'Yes' for _, c in jogo)}"
      f" No={sum(c == 'No' for _, c in jogo)}")

# contagens usadas no relatório
nomes = ["Outlook", "Temp", "Humidity", "Wind"]
for i, nome in enumerate(nomes):
    vals = sorted(set(x[i] for x, _ in jogo))
    txt = []
    for v in vals:
        s = sum(1 for x, c in jogo if x[i] == v and c == "Yes")
        n = sum(1 for x, c in jogo if x[i] == v and c == "No")
        txt.append(f"{v}: {s}/{n}")
```

```

    print(f" {nome} (Yes/No) " + " ".join(txt))

for rotulo, ex in [("a", ["Sunny", "Cool", "High", "Strong"]),
                  ("b", ["Overcast", "Hot", "Normal", "Strong"]),
                  ("c", ["Rainy", "Cool", "High", "Weak"])]):
    print(f" {rotulo} {ex}: {mostrar(naive_bayes(jogo, ex))}")

# questao 3
print("\n[3] f = x1 or (not x1 and x2 and x3), 64 instâncias")
booleana = []
for x in product([0, 1], repeat=6):
    f = x[0] or (not x[0] and x[1] and x[2])
    booleana.append((list(x), int(f)))
print(f" positivos={sum(c for _, c in booleana)}"
      f" negativos={sum(1 - c for _, c in booleana)}")
for c in [1, 0]:
    linhas = [x for x, y in booleana if y == c]
    probs = [F(sum(x[i] for x in linhas), len(linhas)) for i in range(6)]
    print(f" classe {c}: P(xi=1|c) = " + " ".join(str(p) for p in probs))
for ex in ["100010", "011011"]:
    x = [int(ch) for ch in ex]
    real = int(x[0] or (not x[0] and x[1] and x[2]))
    print(f" {ex}: {mostrar(naive_bayes(booleana, x))} (f real = {real})")

# quantas das 64 o Naive Bayes acerta
acertos = 0
erros = []
for x, y in booleana:
    s = naive_bayes(booleana, x)
    pred = max(s, key=s.get)
    if pred == y:
        acertos += 1
    else:
        erros.append(" ".join(map(str, x)))
print(f" acerta {acertos} de 64; erra em {erros}")

# questao 4
print("\n[4] base dos computadores")
dados = """Producao Menos6 Baixa Nao Baixo
Escritorio Mais1ano Alta Sim Alto
Producao Mais1ano Baixa Nao Baixo
Escritorio Menos6 Alta Sim Alto
Producao Entre6e1 Baixa Nao Baixo
Escritorio Menos6 Baixa Sim Baixo
Producao Mais1ano Alta Nao Alto
Escritorio Menos6 Alta Nao Baixo
Producao Entre6e1 Baixa Sim Baixo
Escritorio Entre6e1 Alta Sim Alto"""
pcs = []
for linha in dados.split("\n"):
    p = linha.split()
    pcs.append((p[:4], p[4]))
valores = [sorted(set(x[i] for x, _ in pcs)) for i in range(4)]

# validação cruzada com 5 dobras de 2 computadores, na ordem da tabela
print(" 5 dobras, com Laplace:")
acertos = 0
zerados = 0
for k in range(5):
    teste = pcs[2 * k:2 * k + 2]
    treino = pcs[:2 * k] + pcs[2 * k + 2:]
    for x, y in teste:
        s = naive_bayes(treino, x, laplace=True, valores=valores)
        pred = max(s, key=s.get)
        acertos += pred == y
        print(f" dobra {k + 1}: PC {pcs.index((x, y)) + 1} real={y}"
              f" previsto={pred} {mostrar(s)}")
    # sem Laplace, quantos testes zeram as duas classes
    if all(v == 0 for v in naive_bayes(treino, x).values()):
        zerados += 1
print(f" acurácia 5 dobras: {acertos}/10")
print(f" sem Laplace, {zerados} dos 10 testes zeram as duas classes")

```

```

# deixa um de fora com Laplace, igual ao Weka com 10 dobras em 10 exemplos
print(" deixando um de fora, com Laplace (como o Weka):")
acertos = 0
for i, (x, y) in enumerate(pcs):
    treino = pcs[:i] + pcs[i + 1:]
    s = naive_bayes(treino, x, laplace=True, valores=valores)
    pred = max(s, key=s.get)
    acertos += pred == y
    print(f"    PC {i + 1}: real={y} previsto={pred} {mostrar(s)}")
print(f" acurácia deixando um de fora com Laplace: {acertos}/10")

# questao 5
print("\n[5] doentes e saudáveis")
# atributos N, C, R, F
sintomas = [[([1, 1, 1, 0], "ill"), ([1, 1, 0, 0], "ill"),
              ([0, 0, 1, 1], "ill"), ([1, 0, 0, 0], "healthy"),
              ([0, 0, 0, 0], "healthy"), ([0, 1, 1, 0], "healthy")]
for nome, ex in [("d7", [0, 1, 0, 1]), ("d8", [1, 0, 0, 1]),
                 ("d9", [1, 0, 1, 0])]:
    print(f" {nome}: {mostrar(naive_bayes(sintomas, ex))}")
    s = naive_bayes(sintomas, ex, laplace=True, valores=[[0, 1]] * 4)
    print(f"      com Laplace: {mostrar(s)}")

```